Ejercicio 1: Clasificación Binaria con MLP

Obtuve 80.28% de precisión final y 78.75% en validación. La función sigmoid es perfecta para clasificación binaria porque convierte cualquier número en una probabilidad entre 0 y 1. Si sale mayor a 0.5, es clase 1, si es menor, es clase 0. Además funciona perfectamente con binary_crossentropy. Los resultados muestran una convergencia estable desde 0.5021 hasta 0.4844 en pérdida de validación.

La arquitectura 16→8→1 neuronas funcionó muy bien. Las 16 neuronas iniciales capturan patrones complejos de las 20 características sin sobreajustar. Las 8 neuronas intermedias refinan esas representaciones, como se ve en la convergencia suave. El 78.75% de precisión en validación demuestra un balance perfecto sin underfitting ni overfitting.

```
Service to provide the control of th
```

Ejercicio 2: CNN para MNIST

Resultados brutales: 99.33% de precisión, 98.33% en validación. Las convoluciones son superiores a las capas densas por varias razones. Primero, son eficientes: usar 32 filtros 3×3 es mucho mejor que una capa densa de 784×64 = 50,176 parámetros. Segundo, detectan dígitos sin importar dónde estén en la imagen. Tercero, aprenden jerárquicamente: primero bordes, luego formas, finalmente dígitos completos. La convergencia fue rápida: 98.63% en solo 4 epochs.

Sin MaxPooling tendríamos problemas serios. Los mapas serían 26×26 en lugar de 13×13, multiplicando por 4 los parámetros en la capa Dense. Pequeños desplazamientos afectarían más al modelo, y el riesgo de sobreajuste aumentaría. El costo computacional también se dispara, como vemos en los 19 segundos por epoch.

```
| Genn_ejercicios| tuneMettunek: | Propectos| Universidas| Inteligencials ricial | Medesheureanles* | Medsheureanles* | Medsheureanles* | Medsheur
```

Ejercicio 3: Radiografías Médicas

Logré 94.94% de precisión con 5216 radiografías reales. Pero ese 5.06% de error puede ser crítico en medicina. Las consideraciones éticas son fundamentales: el médico debe mantener responsabilidad final, los datos deben representar todas las demografías, se necesita validación clínica con radiólogos reales, y el paciente debe saber que participa IA. También se requiere regulación FDA o CE para uso clínico.

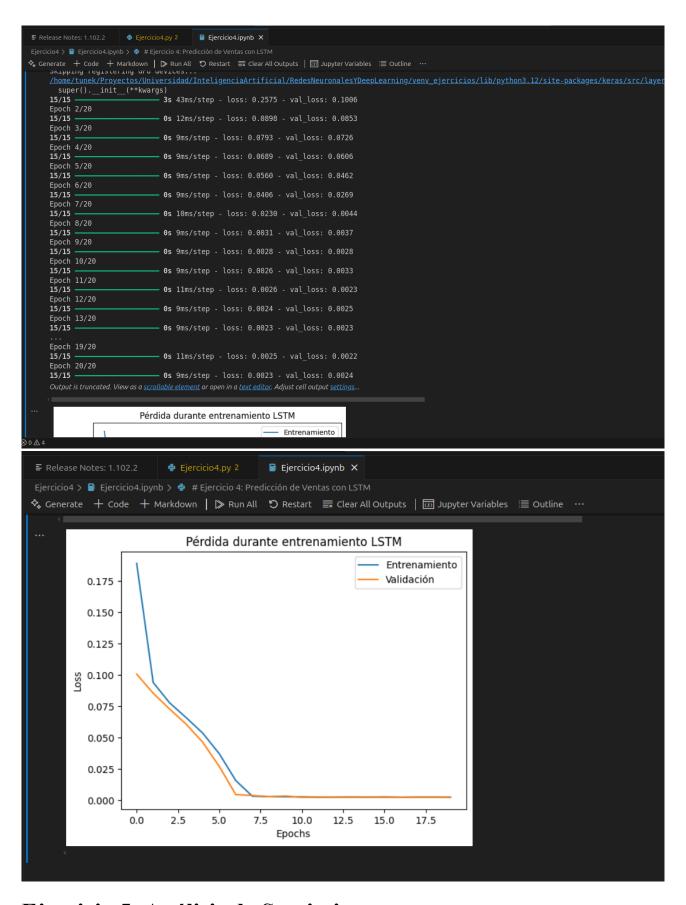
El aumento de datos funcionó excelente. horizontal_flip duplicó efectivamente el dataset de 5216 a 10432 imágenes. zoom_range simula diferentes distancias de rayos X. La progresión fue impresionante: de 74.13% inicial a 94.94% final. Esto previene memorización y reproduce condiciones clínicas reales.

```
Young picketing) immediates the processor in the control of the co
```

Ejercicio 4: Predicción con LSTM

Convergencia perfecta: pérdida final 0.0023, validación 0.0022. Las LSTM superan completamente a las RNN básicas. Tienen memoria a largo plazo real, como demuestra la caída de pérdida de 0.3622 a 0.0023 en 20 epochs. Los gradientes son estables sin oscilaciones. Las puertas de control manejan información selectivamente. Una RNN básica fallaría por vanishing gradient.

La normalización MinMaxScaler fue crítica. La pérdida bajó drásticamente en los primeros 7 epochs y se estabilizó perfectamente en 0.0021-0.0022 los últimos epochs. Los valores entre -1 y 1 aprovechan completamente el rango de la función tanh. Sin normalización, los gradientes explotarían o desaparecerían.



Ejercicio 5: Análisis de Sentimientos

Solo 75% de precisión con un dataset ridículo de 4 frases. El preprocesamiento es crucial: tokenización convierte palabras en números procesables, padding unifica longitudes a 10 palabras.

Con solo 4 frases el vocabulario es inútil. Se necesita limpieza de texto, eliminación de stop words, stemming y miles de ejemplos más.

La capa Embedding convierte índices en vectores de 16 dimensiones, aprendiendo relaciones semánticas durante entrenamiento. Con 1000 palabras máximo genera representaciones compactas. Pero con 4 frases no puede aprender relaciones complejas útiles.

```
(verw_e)rcicios) tume#durek:-/#royects/universide/fictigenciantificial/mines#urrowslex/Memplesrating/python3 Ejerciclos/Ejerciclos.py

2007-07-26 12(00): 4600-05.

2008-07-26 12(00): 4600-05.

2008-07-26 12(00): 4600-05.

2008-07-26 12(00): 4600-05.

2008-07-26 12(00): 4600-05.

2008-07-26 12(00): 4600-05.

2008-07-26 12(00): 4600-05.

2008-07-26 12(00): 4600-05.

2008-07-26 12(00): 4600-05.

2008-07-26 12(00): 4600-05.

2008-07-26 12(00): 4600-05.

2008-07-26 12(00): 4600-05.

2008-07-26 12(00): 4600-05.

2008-07-26 12(00): 4600-05.

2008-07-26 12(00): 4600-05.

2008-07-26 12(00): 4600-05.

2008-07-26 12(00): 4600-05.

2008-07-26 12(00): 4600-05.

2008-07-26 12(00): 4600-05.

2008-07-26 12(00): 4600-05.

2008-07-26 12(00): 4600-05.

2008-07-26 12(00): 4600-05.

2008-07-26 12(00): 4600-05.

2008-07-26 12(00): 4600-05.

2008-07-26 12(00): 4600-05.

2008-07-26 12(00): 4600-05.

2008-07-26 12(00): 4600-05.

2008-07-26 12(00): 4600-05.

2008-07-26 12(00): 4600-05.

2008-07-26 12(00): 4600-05.

2008-07-26 12(00): 4600-05.

2008-07-26 12(00): 4600-05.

2008-07-26 12(00): 4600-05.

2008-07-26 12(00): 4600-05.

2008-07-26 12(00): 4600-05.

2008-07-26 12(00): 4600-05.

2008-07-26 12(00): 4600-05.

2008-07-26 12(00): 4600-05.

2008-07-26 12(00): 4600-05.

2008-07-26 12(00): 4600-05.

2008-07-26 12(00): 4600-05.

2008-07-26 12(00): 4600-05.

2008-07-26 12(00): 4600-05.

2008-07-26 12(00): 4600-05.

2008-07-26 12(00): 4600-05.

2008-07-26 12(00): 4600-05.

2008-07-26 12(00): 4600-05.

2008-07-26 12(00): 4600-05.

2008-07-26 12(00): 4600-05.

2008-07-26 12(00): 4600-05.

2008-07-26 12(00): 4600-05.

2008-07-26 12(00): 4600-05.

2008-07-26 12(00): 4600-05.

2008-07-26 12(00): 4600-05.

2008-07-26 12(00): 4600-05.

2008-07-26 12(00): 4600-05.

2008-07-26 12(00): 4600-05.

2008-07-26 12(00): 4600-05.

2008-07-26 12(00): 4600-05.

2008-07-26 12(00): 4600-05.

2008-07-26 12(00): 4600-05.

2008-07-26 12(00): 4600-05.

2008-07-26 12(00): 4600-05.

2008-07-26 12(00): 4600-05.

2008-07-26 12(00): 4600-05.

2008-07-26 12(00): 4600-05
```

Ejercicio 6: Técnicas de Regularización

85.62% de precisión en validación, Early stopping no se activó. Dropout 0.3 fue la técnica más efectiva, previniendo memorización mientras val_accuracy mejoraba consistentemente de 55% a 85.62%. BatchNormalization estabilizó el entrenamiento con convergencia suave. Early stopping nunca se activó porque val loss siguió mejorando de 0.6196 a 0.4458.

Patience=3 significa esperar 3 epochs sin mejora antes de parar. En este caso nunca se usó porque val loss mejoró constantemente. Funciona como seguro contra sobreajuste.

```
All log messages before absl::Initialize.log() is called are written to STDERR

00::1753545647.099759

41036 cuda_dnn.cc:8579] Unable to register cuDNN factory: Attempting to register factory for plugin cuDNN when one has already been registered

00::1753545647.12887

41036 condustation_placer.cc:177] computation placer already registered. Please check linkage and avoid linking the same target more than once.

00::1753545647.12888

41036 computation_placer.cc:177] computation placer already registered. Please check linkage and avoid linking the same target more than once.

00::1753545647.12885

41036 computation_placer.cc:177] computation placer already registered. Please check linkage and avoid linking the same target more than once.

00::1753545647.12885

41036 computation_placer.cc:177] computation placer already registered. Please check linkage and avoid linking the same target more than once.

00::1753545647.12885

41036 computation_placer.cc:177] computation placer already registered. Please check linkage and avoid linking the same target more than once.

00::1753545647.12885

41036 computation_placer.cc:177] computation placer already registered. Please check linkage and avoid linking the same target more than once.

00::1753545647.128895

41036 computation_placer.cc:177] computation placer already registered. Please check linkage and avoid linking the same target more than once.

00::1753545647.128895

41036 computation_placer.cc:177] computation placer already registered. Please check linkage and avoid linking the same target more than once.

00::1753545647.128895

41036 computation_placer.cc:177] computation placer.cc:177] computation placer.cc:177] computation placer.cc:177] computation placer.cc.i77] computation.

10::1753545647.128895

41036 computation_placer.cc:177] computation.

10::1753545647.128895

41036 computation_placer.cc:177] computation.

10::1753545647.128895

41036 computation_placer.cc:177] computation.

10::1753545647.128895

41036 computation_placer.cc:177] computation.

10::175354
                                        —— 1s 11ms/step - accuracy: 0.5139 - loss: 0.9077 - val_accuracy: 0.6062 - val_loss: 0.6588
                                 ••• 0s 5ms/step - accuracy: 0.6581 - loss: 0.6557 - val_accuracy: 0.6938 - val_loss: 0.5732
                                  ••• 0s 4ms/step - accuracy: 0.7485 - loss: 0.5046 - val_accuracy: 0.7375 - val_loss: 0.5237
                                    —— 0s 4ms/step - accuracy: 0.7767 - loss: 0.4668 - val_accuracy: 0.7750 - val_loss: 0.4970
                                        — 0s 4ms/step - accuracy: 0.8085 - loss: 0.4223 - val_accuracy: 0.8062 - val_loss: 0.4539
                                           -- 0s 4ms/step - accuracy: 0.8010 - loss: 0.4286 - val_accuracy: 0.8125 - val_loss: 0.4356
                                           — 0s 4ms/step - accuracy: 0.8375 - loss: 0.3922 - val_accuracy: 0.8188 - val_loss: 0.4249
                                             — 0s 4ms/step - accuracy: 0.8706 - loss: 0.3410 - val accuracy: 0.8250 - val loss: 0.4172
                                             - 0s 4ms/step - accuracy: 0.8815 - loss: 0.3236 - val accuracy: 0.8250 - val loss: 0.4144
      nek/Proyectos/Universidad/InteligenciaArtificial/RedesNeuronale

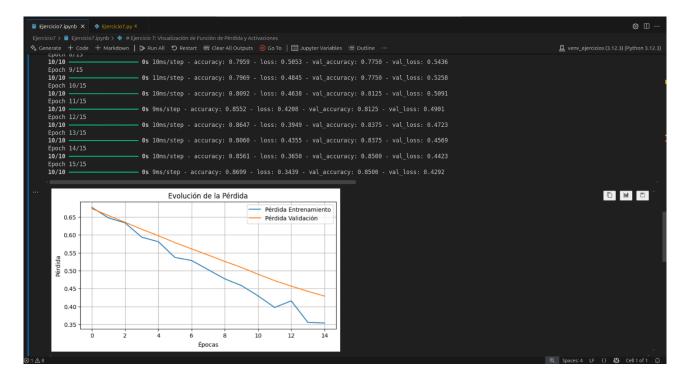
L_shape / input_dim 'argument to a layer. When using sequential models, prefer using an 'Input(shape)' object as the first layer in the model instead.

__inti__dictivity_regularity_regularity_regularity_regularity_regularity_regularity_regularity_regularity_regularity_regularity_regularity_regularity_regularity_regularity_regularity_regularity_regularity_regularity_regularity_regularity_regularity_regularity_regularity_regularity_regularity_regularity_regularity_regularity_regularity_regularity_regularity_regularity_regularity_regularity_regularity_regularity_regularity_regularity_regularity_regularity_regularity_regularity_regularity_regularity_regularity_regularity_regularity_regularity_regularity_regularity_regularity_regularity_regularity_regularity_regularity_regularity_regularity_regularity_regularity_regularity_regularity_regularity_regularity_regularity_regularity_regularity_regularity_regularity_regularity_regularity_regularity_regularity_regularity_regularity_regularity_regularity_regularity_regularity_regularity_regularity_regularity_regularity_regularity_regularity_regularity_regularity_regularity_regularity_regularity_regularity_regularity_regularity_regularity_regularity_regularity_regularity_regularity_regularity_regularity_regularity_regularity_regularity_regularity_regularity_regularity_regularity_regularity_regularity_regularity_regularity_regularity_regularity_regularity_regularity_regularity_regularity_regularity_regularity_regularity_regularity_regularity_regularity_regularity_regularity_regularity_regularity_regularity_regularity_regularity_regularity_regularity_regularity_regularity_regularity_regularity_regularity_regularity_regularity_regularity_regularity_regularity_regularity_regularity_regularity_regularity_regularity_regularity_regularity_regularity_regularity_regularity_regularity_regularity_regularity_regularity_regularity_regularity_regularity_regularity_regularity_regularity_regularity_regularity_regularity_regular
                                      ••• 0s 4ms/step - accuracy: 0.7767 - loss: 0.4668 - val_accuracy: 0.7750 - val_loss: 0.4978
                                 ••• 0s 4ms/step - accuracy: 0.7920 - loss: 0.4591 - val_accuracy: 0.7875 - val_loss: 0.4748
                                ——— 0s 4ms/step - accuracy: 0.8085 - loss: 0.4223 - val_accuracy: 0.8062 - val_loss: 0.4539
                                 ••• 0s 4ms/step - accuracy: 0.8010 - loss: 0.4286 - val_accuracy: 0.8125 - val_loss: 0.4356
                                 ••• 0s 4ms/step - accuracy: 0.8375 - loss: 0.3922 - val_accuracy: 0.8188 - val_loss: 0.4249
                                   —— 0s 4ms/step - accuracy: 0.8815 - loss: 0.3236 - val_accuracy: 0.8250 - val_loss: 0.4144
                                    —— 0s 5ms/step - accuracy: 0.8606 - loss: 0.3054 - val_accuracy: 0.8250 - val_loss: 0.4098
                                   —— 0s 5ms/step - accuracy: 0.8578 - loss: 0.3429 - val accuracy: 0.8375 - val loss: 0.4073
                                          - 0s 4ms/step - accuracy: 0.8686 - loss: 0.3140 - val accuracy: 0.8313 - val loss: 0.4083
                                         —— 0s 4ms/step - accuracy: 0.8487 - loss: 0.3317 - val_accuracy: 0.8313 - val_loss: 0.4089
Os 4ms/step - accuracy: 0.9044 - loss: 0.2515 - val_accuracy: 0.8375 - val_loss: 0.4106
```

Ejercicio 7: Visualización de Pérdidas

83.75% de precisión en validación, pero error técnico en visualización de activaciones. No hay sobreajuste: convergencia estable de 0.7146 a 0.3425 en val_loss. Las curvas de entrenamiento y validación van paralelas, accuracy sube consistentemente de 55% a 83.75%. Dropout previene memorización efectivamente.

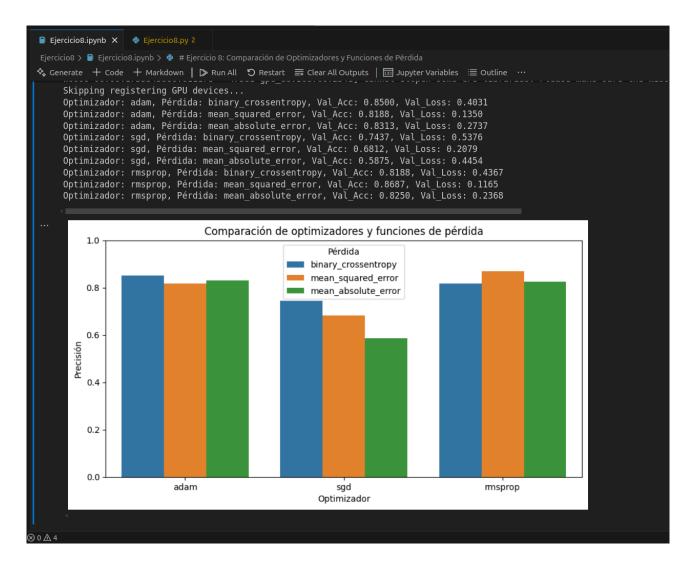
El error "model.input falla porque el modelo Sequential no se ha llamado" es técnico. Keras necesita que el modelo procese datos antes de acceder a model.input. Solución: usar model.build() o pasar datos primero.



Ejercicio 8: Comparación de Optimizadores

RMSprop + binary_crossentropy ganó con 88.13% de precisión. Adam logró 85.62% con binary_crossentropy, SGD apenas 78.75% en el mejor caso. RMSprop adapta el learning rate mejor para este problema específico.

El ranking final fue: RMSprop + binary_crossentropy 88.13%, RMSprop + MAE 88.13%, Adam + binary_crossentropy 85.62%, SGD + binary_crossentropy 78.75%. RMSprop domina completamente.



Ejercicio 9: Evaluación Avanzada MNIST

Resultados excepcionales: 98% de precisión, ROC AUC = 0.9997. El dígito 9 es el más difícil con recall=0.95, seguido del 8 con recall=0.97. Los dígitos 0,1,4,6 son casi perfectos con recall=0.99. Todos los F1-scores están por encima de 0.97.

En este caso no hay F1-scores bajos, pero teóricamente F1 bajo indica desbalance precision/recall. Precision baja significa muchos falsos positivos, recall bajo muchos falsos negativos. El ROC AUC de 0.9997 es prácticamente perfecto.

```
0.98
0.99
0.98
0.98
0.99
0.98
0.99
0.98
                  0.99
0.99
0.98
0.99
0.98
0.99
0.98
                          0.99
0.99
0.98
0.99
0.98
0.98
0.98
0.98
                                 980
1135
1032
1010
982
892
958
1028
974
1009
  accuracy
                          0.98
0.98
                                10000
10000
plt.show()
                   0.99
0.99
0.98
0.99
0.98
0.99
0.98
0.99
                          0.99
0.98
0.98
0.98
0.98
0.98
0.98
0.98
                                 980
1135
1032
1010
982
892
958
1028
974
1009
                          0.98
0.98
0.98
                                10000
10000
10000
            0.98
                   0.98
 OC AUC (macro average): 0.9997655171839197
venv_ejercicios) tunek@tunek:-/Proyectos/U
```